



Deployment-Oriented Neural Network State Estimation for Battery Management Systems

Florian Rzepka | Technische Universität Berlin | Disputation 2026


Gliederung

1. Motivation und Forschungsfragen
2. Bewertungsrahmen und experimentelle Basis
3. Kompakte neuronale Alterungsbestimmung
4. Robustheitsbenchmark
5. Embedded AI und Modellkompression
6. Gesamtergebnisse und Ausblick

Motivation und Forschungsfragen

Warum deployment-orientierte Zustandsbestimmung?

- Stationäre Microgrids und mobile Systeme mit begrenzter Kommunikation oder Wartung
- SOC und SOH müssen lokal, kontinuierlich und kausal verfügbar sein
- Embedded systems begrenzen Speicher, Rechenzeit und Energie
- Praktische Eignung verbindet Accuracy, Robustness und Hardwarebedarf



Lokale Zustandsbestimmung als Voraussetzung für autonomen Betrieb

1. Motivation

2. Framework

3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse

Forschungsfragen und roter Faden



- RQ1: Wie komplex müssen neuronale Netze für eine genaue SOC- und SOH-Bestimmung tatsächlich sein?
- RQ2: Wie verändern Messstörungen und Zustandsfehler die Zuverlässigkeit verschiedener Estimator-Klassen?
- RQ3: Wie lassen sich neuronale Estimatoren innerhalb der Memory-, Latency- und Energy-Limits eines BMS einsetzen?

1. Motivation

2. Framework

3. Ageing


4. Robustness

5. Embedded AI

6. Ergebnisse

Bewertungsrahmen und experimentelle Basis

BMS-Anforderungen als gemeinsamer Bewertungsrahmen



Gemeinsame Bewertung

- SOC und SOH sind interne, nicht direkt messbare Zustände
- Reale Signale enthalten Bias, Noise, Dropouts und Timingfehler
- Flash, RAM, Latency und Energy setzen harte Grenzen
- Accuracy allein beschreibt keine Deployment-Eignung

1. Motivation

2. Framework


3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse

Estimator-Klassen und Evaluationslogik



- Ein gemeinsamer Messstrom trennt Modellverhalten von Testbedingungen
- Der jeweilige Korrekturmechanismus bestimmt die Fehlersensitivität
- Baseline accuracy, disturbance response und recovery werden getrennt bewertet

1. Motivation

2. Framework

3. Ageing


4. Robustness

5. Embedded AI

6. Ergebnisse


Datenbasis und Embedded Zielsystem

Datenbasis



- NMC: 14 Zellen und 7 Alterungsszenarien
- LFP: 15 Zellen, 8 operating points und 1-Hz stream

Custom BMS und Zielhardware



Gemeinsame Basis für sensing, firmware und inference

1. Motivation

2. Framework

3. Ageing


4. Robustness

5. Embedded AI

6. Ergebnisse

Kompakte neuronale Alterungsbestimmung

Zeitliche Information statt größerem Netz




Expliziter zeitlicher Kontext

- Die Historie wird in den Feature-Vektor verlagert
- Das MLP benötigt dadurch keinen recurrent state
- Die Kontextlänge steuert Informationsgehalt und Eingangsgröße

1. Motivation
2. Framework
3. Ageing
4. Robustness
5. Embedded AI
6. Ergebnisse


Kompakte MLP-Architektur für die SOH-Bestimmung



- Bewusst einfache feedforward architecture als Test der Repräsentation
- Zeitliche Information entsteht außerhalb des Netzes durch Feature Engineering
- Modellkapazität und zeitliche Informationsaufbereitung bleiben getrennt bewertbar

1. Motivation
2. Framework
- 3. Ageing**
4. Robustness
5. Embedded AI
6. Ergebnisse

Ergebnis: Kleine Netze bei geeigneter Repräsentation



1,10 pp

mittlerer SOH MAE

160 min

beste History-Konfiguration


Cell 9

Grenze bei atypischer Alterung

1. Motivation
2. Framework
- 3. Ageing**
4. Robustness
5. Embedded AI
6. Ergebnisse

Robustheitsbenchmark


Vergleich von vier Estimator-Klassen



- Identischer Messstrom und gleiche Disturbance realizations isolieren das Estimator-Verhalten
- Vier Korrekturprinzipien statt vier unterschiedlich getesteter Modelle
- Getrennte Evidenz für nominale Accuracy, Recovery und Disturbance response

1. Motivation
2. Framework
3. Ageing
- 4. Robustness**
5. Embedded AI
6. Ergebnisse

Nominale Accuracy ist nur der Ausgangspunkt



- Unter nominalen Signalen profitiert HDM von der SOH-gestützten Kapazitätsanpassung
- Die clean ranking dient nur als Referenz für die Disturbance tests
- Der niedrigste MAE sagt noch nichts über Drift oder Recovery aus

1. Motivation

2. Framework


3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse


Disturbances verändern die Estimator-Rangfolge



- Persistenter Bias akkumuliert in integrationsbasierten Pfaden
- Voltage feedback begrenzt systematischen Drift
- Temporal context unterstützt bei Dropouts und Recovery
- Die Rangfolge folgt dem dominanten Fehlermechanismus

1. Motivation
2. Framework
3. Ageing
- 4. Robustness**
5. Embedded AI
6. Ergebnisse

Robustness-Ergebnis: kein universeller Sieger



Estimator-Auswahl = relevantes Störprofil + geeigneter Korrekturmechanismus


1. Motivation
2. Framework
3. Ageing
- 4. Robustness**
5. Embedded AI
6. Ergebnisse

Embedded AI und Modellkompression

Vom Modell zur stateful STM32-Ausführung

Custom BMS

Deployment chain



- Sensing, recurrent inference und firmware execution in einer gemeinsamen chain
- Stateful 1-Hz replay mit explizit weitergegebenen LSTM states
- Flash, RAM und kernel time auf dem STM32H755 gemessen

1. Motivation

2. Framework

3. Ageing

4. Robustness



5. Embedded AI

6. Ergebnisse

Zwei Wege der Modellkompression

Structured pruning

INT8 weight quantization




- Komplette hidden channels entfernt
- Kleinere dense tensors nach fine-tuning

- Recurrent weights auf signed INT8 gemappt
- States, scales und MLP bleiben FP32


1. Motivation
2. Framework
3. Ageing
4. Robustness
5. Embedded AI
6. Ergebnisse

Accuracy und Stabilität im Streaming Replay

SOC streaming replay



SOH streaming replay



- SOC MAE [pp]: Base 2,68 | Pruned 2,34 | Quantized 2,79
- SOH MAE [pp]: Base 0,85 | Pruned 1,46 | Quantized 1,41
- Kein wachsender Quantized-to-Base drift im vollständigen replay

1. Motivation

2. Framework


3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse

Trade-offs bei Speicher, Latency und Utility



SOC

- Pruned: -41% Flash | -43% kernel time
- Quantized: -50% Flash | +399% kernel time
- Utility: 0,71 vs. 1,83

SOH

- Pruned: -46% Flash | -44% kernel time
- Quantized: -59% Flash | +29% kernel time
- Hardwarelimit entscheidet

1. Motivation

2. Framework

3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse

Gesamtergebnisse und Ausblick

Kernaussagen der drei Untersuchungen

1 Repräsentation

Explizite Historie
ermöglicht kompakte
Modelle

2 Validierung

Clean accuracy und
Robustness liefern
getrennte Evidenz

3 Implementierung

Compression bleibt
hardware- und
firmwareabhängig

- Task-aligned features können notwendige Modellkomplexität begrenzen
- Clean MAE kann operationale Robustness nicht nachweisen
- Deployment-Eignung entsteht aus der gesamten signal-to-hardware chain

1. Motivation

2. Framework

3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse

Designregeln, Grenzen und nächste Schritte

Kernaussagen

- Representation vor unnötiger Modellkomplexität
- Disturbance tests zusätzlich zu clean MAE
- Compression passend zum tatsächlichen Bottleneck
- Target-hardware validation vor dem Einsatz

Nächste Schritte

- Weitere cells, chemistries und operating profiles
- Fault injection in sensing und firmware
- Joint pruning and quantization
- Größere Packs und autonomer Langzeitbetrieb

1. Motivation

2. Framework

3. Ageing

4. Robustness

5. Embedded AI

6. Ergebnisse

Zielbild: State estimation als integrierte, testbare und resource-aware BMS-Funktion

Vielen Dank | Fragen