

Änderungsübersicht zur grundlegend überarbeiteten Fassung

Performance and Robustness Benchmarking of Battery SOC Estimation Methods for Embedded Applications

Kernaussage. Die Revision ist keine sprachliche oder punktuelle Korrektur der begutachteten Fassung. Die experimentelle Basis, die statistische Einheit, die Definition der Recovery, die Robustheitskampagne, die Embedded-Validierung und die daraus abgeleiteten Schlussfolgerungen wurden neu aufgebaut. Das Paper beantwortet nun die Frage, wie vier konkrete SOC-Implementierungen unter einer gemeinsamen, zellgetrennten und deployment-orientierten Methodik abschneiden. Es leitet ausdrücklich keinen universellen Sieger aus einer einzelnen MAE-Zahl ab.

1. Was unter der Vorgängerversion verstanden wird

Als Vorgängerversion gilt die ursprünglich begutachtete Ein-Zell-Fassung. Sie verwendete eine einzelne repräsentative LFP-Trajektorie, estimatorabhängige Recovery-Schwellen, überwiegend deskriptive Einzelresultate und theoretisch abgeleitete Embedded-Ressourcen. Die aktuelle Fassung basiert dagegen auf einer neuen, zellgetrennten Mehrzellenauswertung mit realen STM32-Messungen.

Ebene	Begutachtete Fassung	Aktuelle Fassung
Datengrundlage	Eine vollständige Zelltrajektorie	Sechs unabhängige Holdout-Zellen und 16 vorab definierte SOH-Fenster
Entwicklungsgrenze	Ausschluss der Testdaten nicht vollständig dokumentiert	Fester Training-, Validierungs- und Holdout-Split für neuronale Modelle, Skalierung und HECM-Parametrisierung
Vergleichseinheit	Einzelne Zeitpunkte und Fenster einer Zelle	Holdout-Zelle als unabhängige statistische Einheit mit gleicher Zellgewichtung
Recovery	Estimatorabhängige Schwellen und nicht äquivalente Auswertung	Gemeinsames 0,02-SOC-Band, 300-s-Haltezeit, persistente Recovery, Relapse und Zensierung
Robustheit	Einzelne Szenarien und überwiegend einzelne Realisierungen	Acht Störungsfamilien, wiederholte Seeds, gepaarte Effekte und Unsicherheitsintervalle
Embedded-Aussage	Ressourcen hauptsächlich berechnet	Auf dem STM32 gemessene Latenz, numerische Äquivalenz und Peak-RAM sowie kompilierter Flash-Bedarf
Schlussfolgerung	Relative Rangfolge aus einer begrenzten Ein-Zell-Auswertung	Deployment-Profil entlang Accuracy, Robustness, Recovery, Latency, Flash und Runtime RAM

2. Quantitativer Umfang der Neuauswertung

- 6 unabhängige Holdout-Zellen mit unterschiedlicher Alterung, Last und Temperatur
- 16 festgelegte Fresh-, Mid-Life- und Aged-Fenster
- 6.720 Läufe mit gemeinsamer Auswertemaske ab Quellsample 2023
- 64 gepaarte Initialisierungsverläufe für die kanonische Recovery-Auswertung
- 10.000 hierarchische Bootstrap-Wiederholungen für 95%-Konfidenzintervalle
- 240 zusätzliche HECM-Läufe für die Lookup-Tabellen-Sensitivität
- Sechs Hardware-Zellsequenzen mit drei Replay-Runden je SOC-Kern
- 25 eindeutig referenzierte Abbildungen einschließlich neuer Appendix-Nachweise

3. Reviewer 1: Darstellung und formale Lesbarkeit

Nr.	Umgesetzte Änderung	Status
1	Zitate und Querverweise werden vollständig aufgelöst. Alle Abbildungen sind in den zugehörigen Abschnitten eingebettet und im Text erläutert.	Beantwortet
2	Die frühere alleinstehende Gleichung für die Ableitungskanäle wurde in die Modellbeschreibung integriert.	Beantwortet
3	Die doppelten Abschnittstitel wurden durch eindeutige Überschriften für SOC- und SOH-Schätzung ersetzt.	Beantwortet

4. Reviewer 2: Experimentelles Design und Fairness

Nr.	Umgesetzte Änderung	Status
1	Die Ein-Zell-Validierung wurde durch sechs zellgetrennte Holdout-Zellen, SOH-Strata und eine explizite Coverage-Darstellung ersetzt. Aussagen werden auf den untersuchten LFP-Bereich begrenzt.	Beantwortet
2	Training, Validierung, Hyperparameterwahl, Skalierung, Pruning und HECM-Identifikation werden dem Development-Split zugeordnet. Keine Holdout-Zelle geht in diese Schritte ein.	Inhaltlich beantwortet, Archivierung offen
3	Alle Modelle erhalten eine Abweichung von 10 SOC-Prozentpunkten über ihren deployment-zugänglichen Zustand. Realisierte Ausgangsabweichung und strukturelle Nichtäquivalenz werden offengelegt.	Beantwortet mit Abgrenzung
4	Estimatorabhängige Recovery-Schwellen wurden vollständig durch ein gemeinsames gepaartes Kriterium ersetzt.	Beantwortet
5	Direkte STM32-Messungen ersetzen die frühere theoretische Embedded-Aussage. Die Grenze auf isolierte SOC-Kerne wird ausdrücklich genannt.	Beantwortet
6	Wiederholte Zufallsrealisierungen, Zell-Makrostatistik, hierarchisches Bootstrap, gepaarte Sign-Flip-Tests, Effektgrößen und Holm-Korrektur wurden ergänzt.	Beantwortet
7	Referenz-SOH-Ablationen trennen den Einfluss des gemeinsamen LSTM-SOH-Dienstes von den SOC-Zweigen.	Beantwortet

5. Reviewer 3: Mechanismen, Grenzen und Reproduzierbarkeit

Nr.	Umgesetzte Änderung	Status
1	Sechs Holdout-Zellen und 16 Zustandsfenster ersetzen die einzelne Trajektorie. Load-, Temperatur- und SOH-Abdeckung werden ausgewiesen.	Beantwortet
2	Die Wahl von LFP wird mit dem kontrollierten DoE-Alterungsdatensatz und der flachen OCV-Kennlinie begründet. Die Übertragbarkeit auf andere Chemien wird begrenzt.	Beantwortet
3	Die Referenz-SOH-Ablation quantifiziert, wie der gemeinsame SOH-Dienst HDM, HECM und DD beeinflusst.	Beantwortet
4	Die stündliche SOH-Aktualisierung wird als kausaler Dienst für graduelle Alterung eingeordnet. Abrupte Kapazitätsverluste sind nicht Teil des Datensatzes.	Beantwortet mit Abgrenzung
5	Der DD-Initialisierungseingriff über Q_c wird als deployment-zugänglicher Proxy und nicht als vollständiger Hidden-State-Cold-Start interpretiert.	Beantwortet mit Abgrenzung
6	Burst Dropout wird als Robustheitsproblem mit einer dauerangepassten 48-h-Baseline behandelt. Die modellabhängigen Ursachen nach Wiederaufnahme der Messung werden erklärt.	Beantwortet
7	Timing Jitter wurde auf $\pm 0,1$, $\pm 0,5$ und $\pm 0,9$ s erweitert und mit mehreren Seeds ausgewertet.	Beantwortet

Nr.	Umgesetzte Änderung	Status
8	Die lokale DD-Spike-Reaktion wird ereignisbezogen ausgewertet und über Spannung, dU/dt und rekurrenten Kontext interpretiert. Eine Kanalablation bleibt eine Erweiterung.	Beantwortet mit Abgrenzung
9	Ein gemeinsames Recovery-Kriterium ersetzt die estimatorabhängigen Bänder.	Beantwortet
10	Peak-RAM umfasst statischen Speicher, maximale dynamische Allokation und gemessene maximale Call-Stack-Nutzung.	Beantwortet
11	Eine neue HECM-Sensitivitätsanalyse untersucht systematische Widerstands- und OCV-Abweichungen über alle sechs Holdout-Zellen.	Beantwortet
12	Referenz-SOH-Läufe zeigen, dass die zusätzliche Temperaturstörung überwiegend nicht durch den gemeinsamen SOH-Dienst erklärt wird.	Beantwortet
13	Die Grenze des measurement-only Designs gegenüber allgemeinem Parameter-Mismatch, Pack-Interaktionen und übergeordneten BMS-Fehlern wird methodisch eingeordnet.	Beantwortet
14	Datensatz, Skripte, Modellkonfigurationen, Seeds, Ergebniszusammenfassungen und Hardwareverfahren werden öffentlich zugeordnet. Die vollständige versionierte Release-Verpackung bleibt ein separater Einreichungsschritt.	Inhaltlich beantwortet, Archivierung offen

6. Neue HECM-Lookup-Sensitivitätsanalyse

Die zusätzliche Analyse beantwortet direkt die Frage, ob die beobachtete Robustheit des HECM lediglich aus einer günstig kalibrierten Lookup-Tabelle entsteht. Untersucht wurden eine einheitliche Skalierung der Widerstände um $\pm 10\%$ und OCV-Verschiebungen um ± 10 mV. Jede Variante wurde nominal und mit gepaartem $\pm 3\%$ -Stromverstärkungsfehler über die sechs Holdout-Zellen ausgeführt.

Lookup-Variante	Baseline-MAE	Adverse 3% Δ MAE
Nominal	0,0337	0,00602
Widerstand -10%	0,0351	0,00614
Widerstand $+10\%$	0,0327	0,00610
OCV -10 mV	0,0314	0,00628
OCV $+10$ mV	0,0373	0,00580

Der größte absolute Makro-Interaktionseffekt beträgt nur 0,000260 MAE. Alle 95%-Intervalle dieses Interaktionseffekts enthalten null. Innerhalb der untersuchten lokalen Abweichungen verändert die Lookup-Kalibrierung daher die absolute HECM-Genauigkeit stärker als die zusätzliche Empfindlichkeit gegenüber dem Stromverstärkungsfehler. Die HECM-Robustheitsaussage ist damit nicht unabhängig von der Kalibrierung, aber sie beruht auch nicht ausschließlich auf einer einzigen exakt passenden Parametertabelle.

7. Warum die Revision als grundlegend einzustufen ist

1. **Die Evidenzbasis wurde ersetzt.** Die zentrale Auswertung beruht nicht mehr auf einer einzelnen Zelltrajektorie, sondern auf unabhängigen Holdout-Zellen und festgelegten Zustandsfenstern.
2. **Die Fairness des Vergleichs wurde neu definiert.** Gemeinsame Auswertemasken, gepaarte Baselines, ein gemeinsames Recovery-Kriterium und die Trennung von Entwicklung und Test verhindern, dass Modellunterschiede durch unterschiedliche Bewertungsregeln entstehen.
3. **Die Unsicherheit ist Teil des Ergebnisses.** Zellvariation, Seeds, Konfidenzintervalle, Effektgrößen und Korrekturen für multiple Vergleiche ersetzen reine Einzelwerte.
4. **Die Embedded-Aussage ist experimentell.** Laufzeit und Peak-RAM wurden auf dem Ziel-Mikrocontroller gemessen. Numerische Hardware-Software-Äquivalenz und verschiedene DD-Inferenzmodi wurden separat geprüft.
5. **Die wissenschaftliche Schlussfolgerung hat sich geändert.** Die aktuelle Arbeit bestimmt keinen universell besten Estimator. Sie zeigt, dass sich Accuracy, störungsspezifische Robustheit, Recovery und Hardwarekosten gegenseitig ergänzen und gemeinsam bewertet werden müssen.
6. **Reviewer-Fragen führten zu neuen Experimenten.** Mehrzellenauswertung, SOH-Ablation, größere Jitter-Stufen, kanonische Recovery, Runtime-RAM-Messung und HECM-Lookup-Sensitivität sind zusätzliche Analysen und keine rein redaktionellen Ergänzungen.

Zusammenfassung: Die überarbeitete Fassung ist methodisch, experimentell und in ihrer Aussage ein neues Benchmark-Paper auf Basis derselben Forschungsfrage. Der Fokus liegt weiterhin auf der Robustheit eingebetteter SOC-Methoden. Die Begründung stützt sich nun jedoch auf zellgetrennte Statistik, explizite Störungsmechanismen, gemeinsame Bewertungsregeln und reale Hardwaremessungen.